Universidade Estadual de Campinas

Departamento de Estatística

ME524 - Computação Aplicada à Estatística

Professor Victor Freguglia Souza

Laboratório 1: Campeonato Brasileiro por MC

César Aleixo de Sousa Silva - 204239
Eduardo Saegi de Souza Hsu - 277142
Marcel Hideki Sousa Adati - 242910
Yejee Kim - 204397

Campinas - SP
Setembro de 2026

Índice

1 Introdução **2**

2 Metodologia **2**
2.1 Descrição da base de dados 2
2.2 Estimação dos parâmetros 3
2.3 Modelo probabilístico para os gols 3
2.4 Simulação do campeonato por Monte Carlo 3
2.5 Variabilidade das estimativas via *bootstrap* 4
2.6 Alteração do modelo 4

3 Resultados **5**
3.1 a) Qual a probabilidade de cada time ser campeão? 5
3.2 b) Qual a probabilidade de cada time ser rebaixado? 6
3.3 c) Qual a probabilidade de o campeonato ser decidido pelos critérios de desempate (duas ou mais equipes empatam em pontos)? 6
3.4 d) Qual o valor esperado do número de pontos do campeão? 7
3.5 e) Quantos pontos uma equipe qualquer precisa fazer para ter pelo menos 90% de chance de ser campeã? 8
3.6 f) Quantos pontos são necessários para que uma equipe qualquer tenha pelo menos 95% de chance de não ser rebaixada? 9
3.7 Distribuição das posições finais nas simulações 10
3.8 Erro padrão das estimativas de Monte Carlo 12

4 Variabilidade das estimativas via Bootstrap **13**

5 Atividade Extra **14**
5.1 Limitações do estudo e considerações finais 18

6 Conclusão **18**

7 Referências **19**

1 Introdução

A modelagem estatística de resultados esportivos constitui uma aplicação relevante de métodos probabilísticos e computacionais, uma vez que os resultados de uma competição são influenciados por diferentes fontes de variabilidade e, portanto, não podem ser determinados de forma completamente antecipada. No contexto do futebol, o número de gols marcados em uma partida apresenta comportamento aleatório, tornando possível sua representação por meio de modelos de probabilidade e a utilização desses modelos para obter previsões sobre os possíveis resultados de uma competição.

Neste trabalho, é proposto um modelo probabilístico simplificado para o número de gols marcados pelas equipes no Campeonato Brasileiro de Futebol. O modelo considera que os gols marcados pelo time mandante e pelo time visitante seguem distribuições de Poisson, cujos parâmetros são determinados a partir das médias de gols marcados e sofridos registradas durante o campeonato pelas equipes, levando em consideração a condição de mandante ou visitante. Dessa forma, as métricas ofensivas e defensivas de cada time observadas nos jogos anteriores são utilizadas para determinar os parâmetros das distribuições associadas às partidas ainda não realizadas.

A partir desse modelo, o método de Monte Carlo foi utilizado para simular repetidamente os jogos restantes do campeonato. Cada simulação representa um possível cenário final para a competição, permitindo obter uma distribuição empírica para diferentes resultados de interesse. A partir das simulações, foram respondidas perguntas de interesse, como as probabilidades de cada equipe conquistar o título e as probabilidades de rebaixamento.

Além da variabilidade inerente aos resultados das partidas, existe também a incerteza associada à estimação dos parâmetros utilizados pelo modelo. Para avaliar tal variabilidade, foi empregado o método *bootstrap*, por meio da reamostragem dos jogos históricos de cada equipe. Deste modo, foram obtidas distribuições empíricas para as estimativas dos parâmetros relacionados aos gols marcados e sofridos, permitindo a construção de intervalos de confiança e a análise da precisão dessas estimativas.

Por fim, propõe-se uma modificação do modelo probabilístico inicialmente considerado, buscando avaliar o efeito da alteração sobre as previsões obtidas. Os resultados do modelo original e do modelo modificado são comparados por meio das probabilidades estimadas e de outras métricas relevantes para a classificação final do campeonato.

2 Metodologia

Nesta seção será explicada a metodologia utilizadada para realização das simulações dos jogos futuros do Campeonato Brasileiro de Futebol de 2026.

2.1 Descrição da base de dados

Neste trabalho, foi utilizada a base de dados `brasileirao_2026.csv`, que contém informações sobre as partidas do Campeonato Brasileiro de Futebol de 2026. O conjunto de dados é composto por cinco variáveis: a rodada do campeonato, o nome do time mandante, o número de gols marcados pelo mandante, o nome do time visitante e o número de gols marcados pelo visitante.

Foram considerados os dados referentes às partidas realizadas até 03/09/2026, não sendo incorporadas informações de jogos posteriores a essa data. As partidas ainda não realizadas foram identificadas pela ausência de valores nas variáveis referentes aos gols, sendo utilizadas posteriormente nas simulações do campeonato.

2.2 Estimação dos parâmetros

Para cada equipe, foram estimados quatro parâmetros relacionados às médias de gols marcados e sofridos, considerando separadamente as condições de mandante e visitante. Denotam-se por θ_m e θ_v as taxas médias de gols marcados por uma equipe atuando como mandante e visitante, respectivamente. Analogamente, ϕ_m e ϕ_v representam as taxas médias de gols sofridos nas condições de mandante e visitante.

Os parâmetros foram estimados por meio das médias amostrais dos gols observados nas partidas realizadas. Assim, para cada equipe, os estimadores são definidos por

$$\widehat{\theta}_m = \frac{\text{total de gols marcados como mandante}}{\text{número de partidas realizadas como mandante}},$$

$$\widehat{\theta}_v = \frac{\text{total de gols marcados como visitante}}{\text{número de partidas realizadas como visitante}},$$

$$\widehat{\phi}_m = \frac{\text{total de gols sofridos como mandante}}{\text{número de partidas realizadas como mandante}},$$

$$\widehat{\phi}_v = \frac{\text{total de gols sofridos como visitante}}{\text{número de partidas realizadas como visitante}}.$$

Dessa forma, os parâmetros estimados sintetizam o desempenho ofensivo e defensivo de cada equipe, levando em consideração a condição em que as partidas foram disputadas.

2.3 Modelo probabilístico para os gols

Para modelar o número de gols marcados em cada partida, foi utilizado o modelo probabilístico simplificado proposto no enunciado. Sejam X_m e X_v as variáveis aleatórias que representam, respectivamente, o número de gols marcados pelo time mandante e pelo time visitante. O modelo é definido por

$$X_m \sim \text{Poisson}\left(\frac{\widehat{\theta}_m + \widehat{\phi}_v}{2}\right),$$

$$X_v \sim \text{Poisson}\left(\frac{\widehat{\theta}_v + \widehat{\phi}_m}{2}\right).$$

Nesse modelo, a taxa esperada de gols de cada equipe depende tanto de sua média de gols marcados quanto da média de gols sofridos pelo adversário, considerando as respectivas condições de mando e visita. Para a simulação das partidas, os gols do mandante e do visitante foram gerados a partir dessas distribuições de Poisson, assumindo-se independência entre as duas variáveis aleatórias.

2.4 Simulação do campeonato por Monte Carlo

Após a estimação dos parâmetros, os jogos ainda não realizados foram simulados por meio do método de Monte Carlo. Foram realizadas $B = 10.000$ simulações do campeonato, sendo que, em cada repetição, os gols das partidas restantes foram gerados de acordo com o modelo probabilístico definido anteriormente.

A partir dos resultados simulados, foi calculada a classificação final de cada repetição, considerando o sistema de pontuação do campeonato: três pontos por vitória, um ponto por empate e

nenhum ponto por derrota. Em caso de igualdade na pontuação, foram aplicados sucessivamente os critérios de desempate: número de vitórias, saldo de gols e número de gols marcados. As quatro equipes nas últimas posições da classificação foram consideradas rebaixadas.

As probabilidades dos eventos de interesse foram estimadas por meio das frequências relativas observadas nas simulações.

2.5 Variabilidade das estimativas via *bootstrap*

Para avaliar a variabilidade dos estimadores dos parâmetros de gols marcados e sofridos, foi utilizado o método *bootstrap*. Para cada equipe e condição de jogo, foram geradas amostras *bootstrap* por meio de reamostragem com reposição das observações disponíveis, mantendo-se o tamanho da amostra original.

Em cada reamostragem, foram recalculadas as médias amostrais correspondentes aos parâmetros θ_m, θ_v, ϕ_m e ϕ_v. Esse procedimento foi repetido 5.000 vezes para cada parâmetro, produzindo distribuições empíricas *bootstrap* das estimativas.

2.6 Alteração do modelo

Como atividade extra, foi proposta uma modificação do modelo probabilístico original, com o objetivo de investigar como uma hipótese adicional pode afetar as previsões do campeonato. A alteração considerada, sua justificativa e a definição matemática do modelo alternativo são apresentadas na seção correspondente.

O modelo modificado foi implementado e utilizado para simular os jogos restantes, seguindo o mesmo procedimento de Monte Carlo empregado no modelo original. Os resultados obtidos foram então comparados por meio das probabilidades estimadas e das demais métricas de interesse, permitindo avaliar as diferenças entre as previsões produzidas pelas duas abordagens.

3 Resultados

Nesta seção são apresentados os resultados obtidos por meio das simulações de Monte Carlo do Campeonato Brasileiro de 2026. Foram realizadas 10.000 simulações dos jogos restantes, utilizando os parâmetros estimados a partir das partidas disponíveis até 03/09/2026. A partir das classificações finais simuladas, foram calculadas as probabilidades dos eventos de interesse e outras métricas relacionadas ao desempenho das equipes.

3.1 a) Qual a probabilidade de cada time ser campeão?

A probabilidade de a equipe i ser campeã é estimada pela proporção de simulações em que ela termina na primeira colocação, considerando um total de B simulações do campeonato. Essa métrica é calculada por

$$\widehat{P}(C_i = 1) = \frac{1}{B} \sum_{b=1}^{B} \mathbf{1}\{C_{ib} = 1\}.$$

Tabela 1: Estimativas de desempenho dos times

Time	Pontos esperados	Desvio	Posição média	Mediana	G4	Campeão
Flamengo	74,62	4,59	1,53	1	99,8%	55,0%
Palmeiras	73,92	4,71	1,70	2	99,5%	42,7%
Athletico-PR	64,47	4,54	3,71	3	78,8%	1,9%
Fluminense	60,82	4,60	5,25	5	45,0%	0,3%
Bahia	58,10	4,59	6,59	6	22,2%	0,0%
Atlético-MG	56,08	4,80	7,45	7	15,7%	0,0%
Cruzeiro	56,14	4,56	7,48	7	13,6%	0,0%
Coritiba	55,19	4,60	8,09	8	9,9%	0,0%
Bragantino	54,97	4,70	8,01	8	10,6%	0,0%
Botafogo	49,95	4,93	11,20	11	1,6%	0,0%
Corinthians	50,58	4,56	10,98	11	1,2%	0,0%
São Paulo	50,48	4,64	10,81	11	1,7%	0,0%
Grêmio	45,79	4,61	13,93	14	0,1%	0,0%
Santos	46,73	4,77	13,38	14	0,3%	0,0%
Vitória	46,19	4,40	13,58	14	0,1%	0,0%
Internacional	42,26	4,58	16,02	16	0,0%	0,0%
Mirassol	40,99	4,52	16,49	17	0,0%	0,0%
Vasco	41,22	4,65	16,40	17	0,0%	0,0%
Remo	38,66	4,48	17,53	18	0,0%	0,0%
Chapecoense	28,26	4,60	19,86	20	0,0%	0,0%

A partir das estimativas obtidas, observa-se que Flamengo e Palmeiras concentram as maiores probabilidades de conquistar o campeonato, com 55% e 42,7%, respectivamente. Em conjunto, essas duas equipes correspondem à maior parte dos títulos observados nas simulações. As probabilidades estimadas para as demais equipes são consideravelmente menores, sendo Athletico-PR e Fluminense aquelas que apresentam os maiores valores entre as equipes restantes, com 1,9% e 0,3%, respectivamente.

Esses resultados refletem os cenários produzidos pelo modelo probabilístico adotado, considerando o desempenho observado das equipes e os jogos restantes.

3.2 b) Qual a probabilidade de cada time ser rebaixado?

Para que um time seja rebaixado à Série B do Brasileirão, a equipe precisa terminar entre as posições 17 e 20 da tabela. Nesse sentido, a probabilidade de rebaixamento é estimada pela frequência relativa, em um total de B simulações, com que a equipe termina a partir da décima sétima posição da classificação final:

$$\widehat{P}(R_i) = \frac{1}{B}\sum_{b=1}^{B} \mathbf{1}\{C_{ib} \geq 17\}.$$

Tabela 2: Probabilidade de rebaixamento dos times

Time	Z4	Última posição
Chapecoense	99,6%	90,2%
Remo	76,6%	4,8%
Mirassol	57,7%	1,7%
Vasco	56,2%	1,6%
Internacional	48,9%	1,3%
Botafogo	4,7%	0,0%
Corinthians	3,1%	0,0%
São Paulo	2,8%	0,0%
Grêmio	19,5%	0,1%
Vitória	15,1%	0,1%
Santos	15,0%	0,1%
Bragantino	0,3%	0,0%
Coritiba	0,2%	0,0%
Atlético-MG	0,1%	0,0%
Cruzeiro	0,1%	0,0%
Flamengo	0,0%	0,0%
Palmeiras	0,0%	0,0%
Athletico-PR	0,0%	0,0%
Fluminense	0,0%	0,0%
Bahia	0,0%	0,0%

De acordo com os resultados, a Chapecoense apresenta a maior probabilidade estimada de rebaixamento, de 99,6%, seguida pelo Remo, com 76,6%, e pelo Mirassol, com 57,7%. Também se destacam Vasco e Internacional, cujas probabilidades estimadas são de 56,2% e 48,9%, respectivamente.

Por outro lado, Flamengo, Palmeiras e Athletico-PR não apresentaram ocorrências de rebaixamento nas simulações realizadas. Esse resultado indica que o evento não foi observado nos 10.000 cenários simulados, não significando que sua probabilidade teórica seja necessariamente igual a zero.

3.3 c) Qual a probabilidade de o campeonato ser decidido pelos critérios de desempate (duas ou mais equipes empatam em pontos)?

A probabilidade de o campeonato ser decidido pelos critérios de desempate é estimada pela proporção de simulações em que duas ou mais equipes terminam com a mesma pontuação máxima. Seja $M_b = \max_i P_{ib}$ a maior pontuação obtida na simulação b. Assim, a probabilidade é estimada por

$$\widehat{P}(D) = \frac{1}{B}\sum_{b=1}^{B} \mathbf{1}\left\{\sum_{i=1}^{20} \mathbf{1}(P_{ib} = M_b) > 1\right\}.$$

A probabilidade estimada foi de 6,07%, indicando que, em aproximadamente 607 simulações, houve mais de uma equipe com a maior pontuação final.

Esse resultado representa a frequência de cenários em que há empate em pontos na liderança. Nesses casos, a classificação entre as equipes empatadas depende dos critérios de desempate estabelecidos para o campeonato, como número de vitórias, saldo de gols e gols marcados.

3.4 d) Qual o valor esperado do número de pontos do campeão?

O valor esperado do número de pontos do campeão é estimado a partir das pontuações das equipes que terminam na primeira colocação em cada simulação. Seja P_{ib} a pontuação da equipe i na simulação b, e C_{ib} sua posição final. O estimador é dado por

$$\widehat{E}(P_{\text{campeão}}) = \frac{\sum_{b=1}^{B} \sum_{i=1}^{20} P_{ib} \mathbf{1}(C_{ib} = 1)}{\sum_{b=1}^{B} \sum_{i=1}^{20} \mathbf{1}(C_{ib} = 1)}.$$

Figura 1: Distribuição dos pontos do campeão

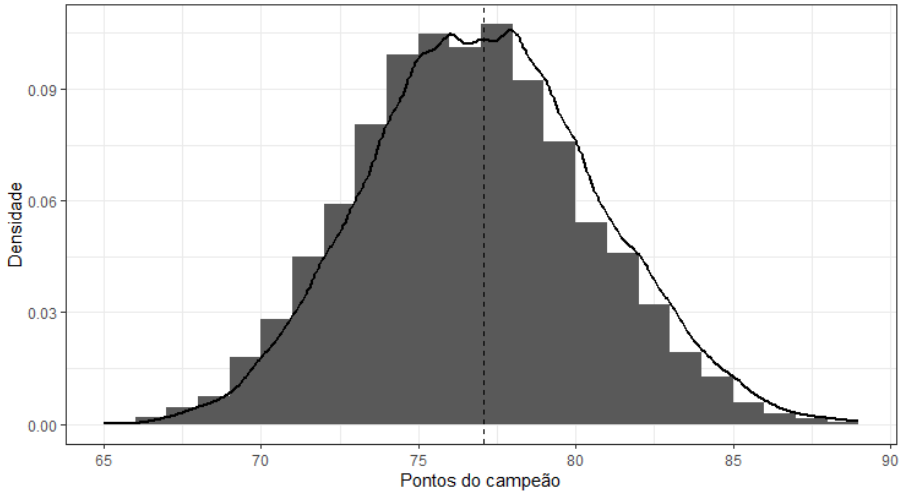


Tabela 3: Estatísticas relacionadas à pontuação do campeão

Média de pontos	Mediana de pontos	Desvio-padrão
77,1	77	3,65

A média estimada da pontuação dos campeões foi de 77,1 pontos, enquanto a mediana foi de 77 pontos. O desvio-padrão de 3,65 pontos indica a dispersão das pontuações dos campeões entre as simulações realizadas.

A proximidade entre a média e a mediana indica que essas duas medidas de tendência central apresentam valores semelhantes na distribuição empírica obtida. A Figura 1 complementa essa análise ao apresentar a distribuição das pontuações dos campeões simulados.

3.5 e) Quantos pontos uma equipe qualquer precisa fazer para ter pelo menos 90% de chance de ser campeã?

A probabilidade de uma equipe qualquer ser campeã, dado que obteve um número p de pontos, pode ser estimada por

$$\widehat{P}(C_i = 1 \mid P_i = p) = \frac{\sum_{b=1}^{B} \mathbf{1}\{P_{ib} = p,\ C_{ib} = 1\}}{\sum_{b=1}^{B} \mathbf{1}\{P_{ib} = p\}}.$$

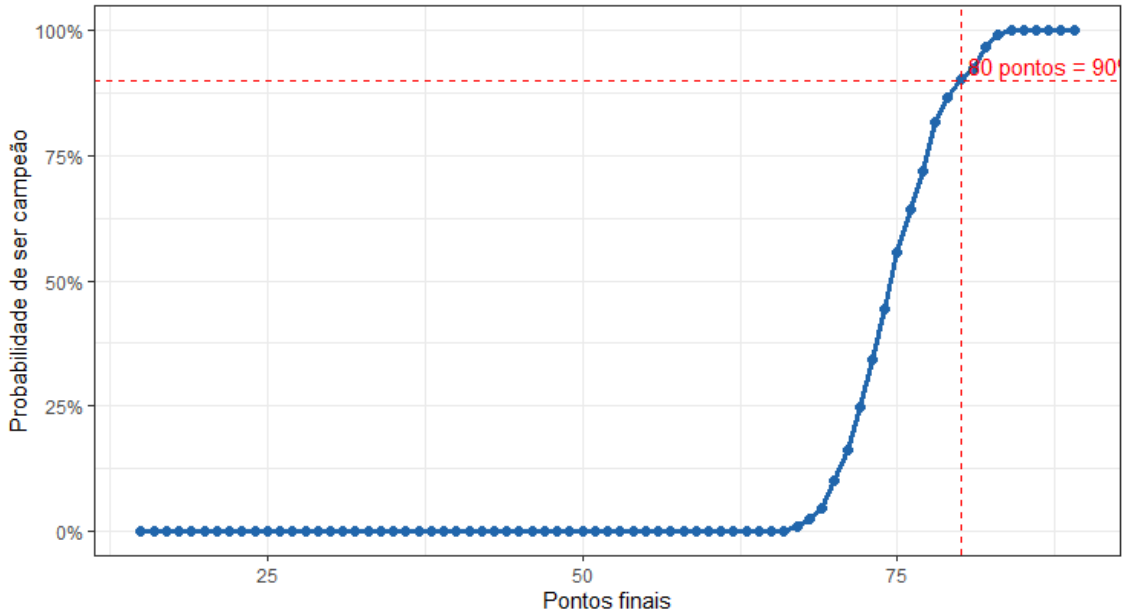
A métrica de interesse é o menor número de pontos para o qual essa probabilidade estimada é de pelo menos 90%. Desse modo, podemos definir

$$p_{90} = \min \left\{ p : \widehat{P}(C_i = 1 \mid P_i = p) \geq 0.90 \right\}.$$

Para cada pontuação observada, estimou-se a probabilidade condicional de um time ser campeão dado que obteve aquela pontuação. A partir dessas estimativas, identificou-se a menor pontuação para a qual a probabilidade estimada de título foi de pelo menos 90%. Estimou-se que são necessários 76 pontos, segundo o modelo adotado.

A probabilidade condicional estimada de título na pontuação-limite foi calculada com base em 839 observações de time-simulação que apresentaram essa pontuação. Esse número corresponde ao conjunto de casos utilizado no cálculo da proporção de campeões entre os times com tal pontuação. Como essa base é relativamente menor, a estimativa pode apresentar maior sensibilidade à variabilidade das simulações.

Figura 2: Probabilidade de ser campeão



3.6 f) Quantos pontos são necessários para que uma equipe qualquer tenha pelo menos 95% de chance de não ser rebaixada?

A probabilidade de que uma equipe qualquer não seja rebaixada, condicionada à sua pontuação final, pode ser obtida por

$$1 - \widehat{P}(R_i \mid P_i = p) = 1 - \frac{\sum_{b=1}^{B} \mathbf{1}\{P_{ib} = p,\ C_{ib} \geq 17\}}{\sum_{b=1}^{B} \mathbf{1}\{P_{ib} = p\}} = \frac{\sum_{b=1}^{B} \mathbf{1}\{P_{ib} = p,\ C_{ib} < 17\}}{\sum_{b=1}^{B} \mathbf{1}\{P_{ib} = p\}}.$$

Definindo

$$1 - \widehat{P}(R_i \mid P_i = p) = \widehat{P}(NR_i \mid P_i = p),$$

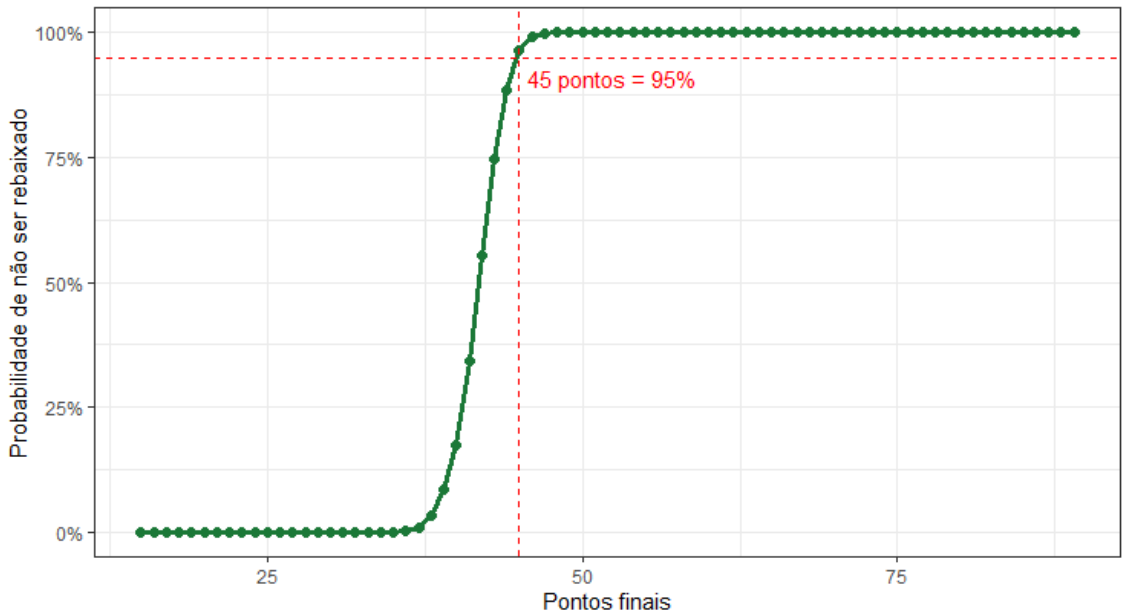
o limiar de pontos necessário para que uma equipe tenha pelo menos 95% de probabilidade de não ser rebaixada é dado por

$$p_{95} = \min \left\{ p : \widehat{P}(NR_i \mid P_i = p) \geq 0.95 \right\}.$$

Para cada pontuação observada, estimou-se a probabilidade condicional de um time não ser rebaixado dado que obteve aquela pontuação. Em seguida, identificou-se a menor pontuação para a qual essa probabilidade estimada foi de pelo menos 95%. Estimou-se que são necessários 45 pontos, segundo o modelo adotado.

A probabilidade condicional estimada de não rebaixamento na pontuação-limite foi calculada com base em 6.381 observações de time-simulação que apresentaram essa pontuação. Esse número corresponde ao conjunto de casos utilizado no cálculo da proporção de times que permaneceram na série entre aqueles com tal pontuação. A maior quantidade de observações proporciona uma base empírica mais ampla para essa estimativa.

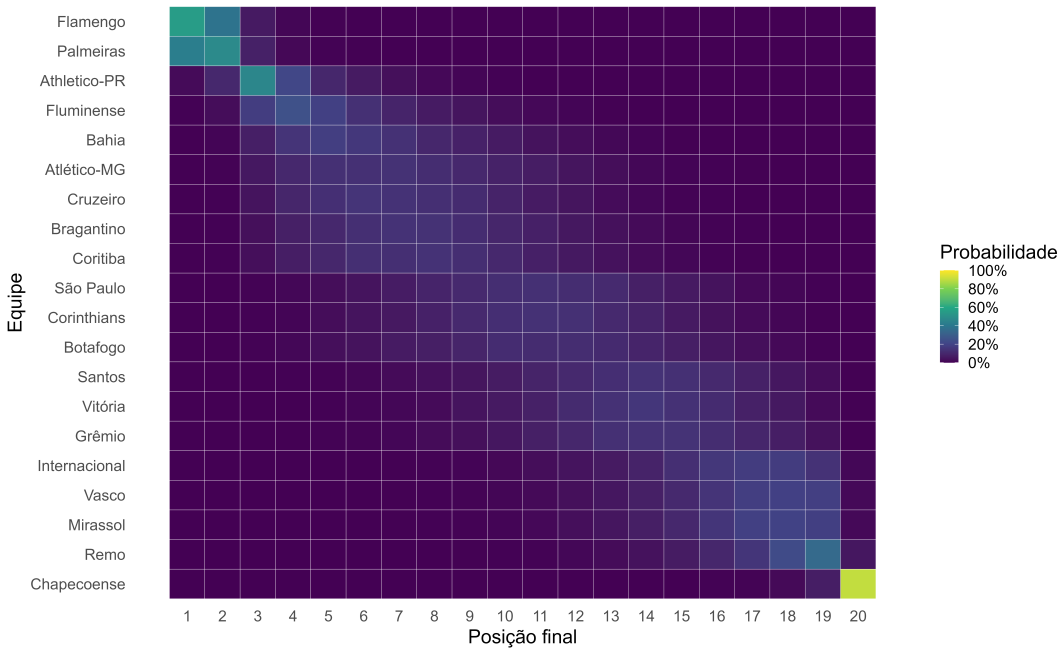
Figura 3: Probabilidade de Ser Rebaixado



3.7 Distribuição das posições finais nas simulações

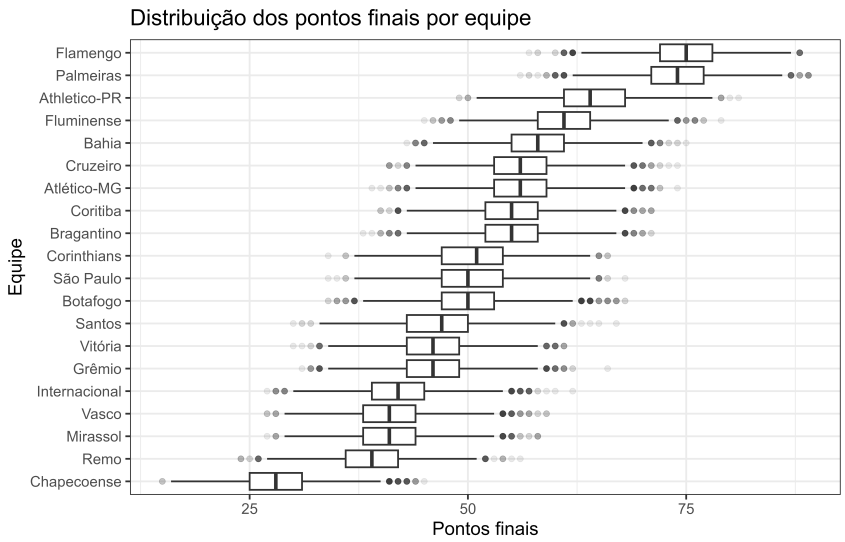
Além das probabilidades específicas de título e rebaixamento, foi analisada a distribuição completa das posições finais das equipes. A Figura 4 apresenta um mapa de calor no qual cada célula representa a probabilidade estimada de uma equipe terminar em determinada colocação.

Figura 4: Distribuição das posições finais de cada equipe



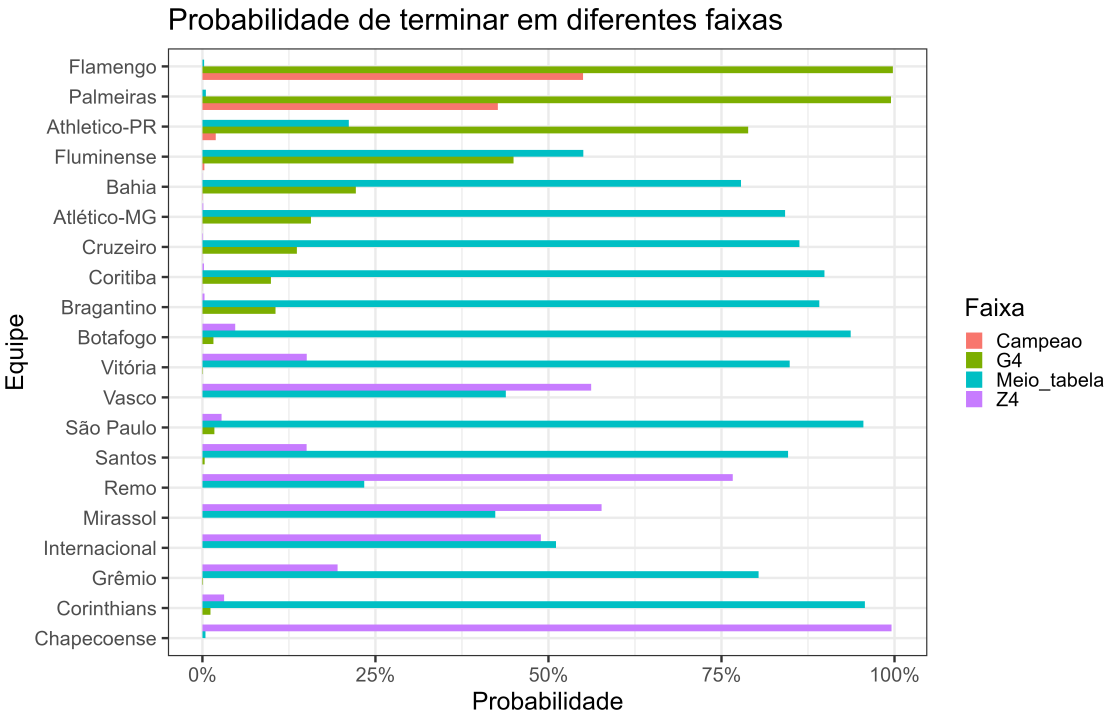
É possível observar a concentração das probabilidades em diferentes regiões da tabela. Essa visualização complementa as probabilidades de título e rebaixamento, pois permite examinar também os cenários intermediários da classificação e a incerteza associada à posição final de cada equipe.

Figura 5: Distribuição dos pontos finais das equipes



A Figura 5 apresenta a distribuição do número de pontos obtidos pelas equipes ao final das simulações. Essa visualização permite observar a variabilidade dos resultados possíveis e comparar a dispersão das pontuações entre as equipes. Nota-se que, embora as equipes possuam pontuações médias distintas, os resultados simulados não são determinísticos, refletindo a incerteza associada às partidas restantes do campeonato. Dessa forma, a distribuição complementa as medidas-resumo apresentadas na tabela, permitindo uma análise mais ampla dos possíveis desfechos da competição.

Figura 6: Probabilidade de cada equipe terminar em cada faixa da tabela



A Figura 6 apresenta as probabilidades estimadas associadas às diferentes faixas de classificação final das equipes. A partir dessa visualização, é possível comparar as chances de cada time terminar em posições distintas, considerando a incerteza incorporada pelas simulações de Monte Carlo. Os resultados evidenciam que as equipes apresentam cenários finais bastante diferentes, desde aquelas concentradas nas primeiras posições até aquelas com maior probabilidade de terminar na parte inferior da tabela. Assim, o gráfico fornece uma visão complementar às probabilidades individuais de título e rebaixamento, permitindo compreender melhor a distribuição dos possíveis desempenhos ao término do campeonato.

3.8 Erro padrão das estimativas de Monte Carlo

Para avaliar a variabilidade decorrente do procedimento de simulação, foram calculados os erros padrão de Monte Carlo das probabilidades estimadas de título, rebaixamento e classificação no G4, bem como da pontuação esperada de cada equipe. Esses valores quantificam a incerteza numérica associada ao uso de um número finito de simulações, permitindo avaliar a precisão das estimativas obtidas.

Para uma probabilidade estimada $\widehat{p}$, o erro padrão de Monte Carlo é dado por

$$EP_{MC}(\widehat{p}) = \sqrt{\frac{\widehat{p}(1-\widehat{p})}{B}},$$

em que B representa o número de temporadas simuladas. Para a pontuação esperada, o erro padrão é calculado por

$$EP_{MC}(\overline{X}) = \frac{s_X}{\sqrt{B}},$$

em que s_X é o desvio padrão das pontuações observadas nas simulações.

Tabela 4: Erros padrão de Monte Carlo das estimativas do modelo original.

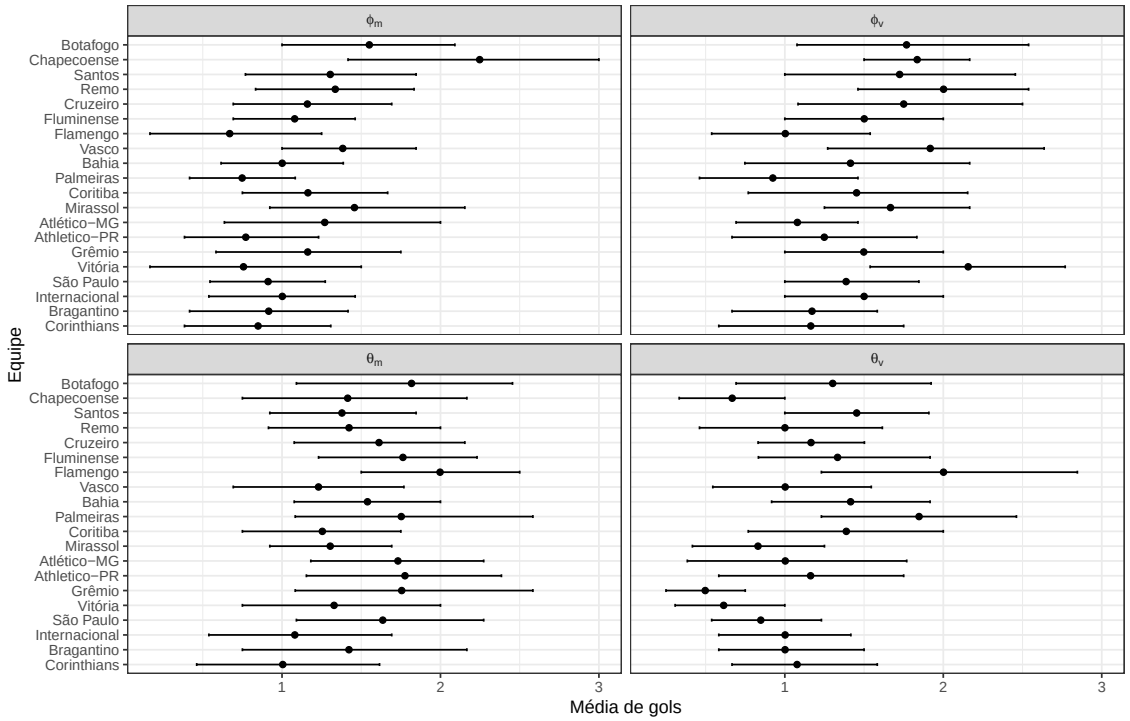
Time	EP_{MC}(campeão)	EP_{MC}(rebaixamento)	EP_{MC}(G4)	EP_{MC}(pontos)
Athletico-PR	0.00137	0	0.00408	0.0454
Atlético-MG	0.000173	0.000360	0.00364	0.0480
Bahia	0.000200	0.000141	0.00415	0.0459
Botafogo	0.000100	0.00212	0.00125	0.0493
Bragantino	0.000100	0.000547	0.00307	0.0470
Chapecoense	0	0	0	0.0460
Corinthians	0	0.00174	0.00107	0.0456
Coritiba	0.000141	0.000469	0.00299	0.0460
Cruzeiro	0.000141	0.000300	0.00343	0.0456
Flamengo	0.00498	0	0.000489	0.0459
Fluminense	0.000528	0.000100	0.00497	0.0460
Grêmio	0	0.00397	0.000300	0.0461
Internacional	0	0.00500	0.000100	0.0458
Mirassol	0	0.00494	0.000100	0.0452
Palmeiras	0.00495	0	0.000705	0.0471
Remo	0	0.00423	0	0.0448
Santos	0	0.00358	0.000565	0.0477
São Paulo	0	0.00164	0.00130	0.0464
Vasco	0	0.00496	0.000100	0.0465
Vitória	0	0.00358	0.000264	0.0440

4 Variabilidade das estimativas via Bootstrap

Para cada uma das 5.000 reamostragens (via *bootstrap*), realizadas para avaliar a variabilidade das estimativas dos parâmetros, foram calculadas as médias de gols marcados e sofridos, considerando separadamente os jogos como mandante e visitante. A partir das distribuições obtidas, foram calculados os intervalos centrais de 95%.

A figura abaixo apresenta as estimativas *bootstrap* para os quatro parâmetros do modelo (θ_m, θ_v, ϕ_m e ϕ_v). Os pontos representam as estimativas médias obtidas nas reamostragens, enquanto as barras horizontais representam os respectivos intervalos de 95%.

Figura 7: Estimativa dos parâmetros por *bootstrap*



A amplitude que varia entre equipes mostra a variabilidade das estimativas. Alguns parâmetros apresentam intervalos relativamente estreitos, enquanto outros possuem intervalos mais amplos, especialmente em equipes para as quais os resultados observados apresentam maior dispersão. Também se observa que as estimativas de gols sofridos (ϕ) e marcados (θ) não apresentam necessariamente a mesma amplitude de intervalo para uma mesma equipe, evidenciando que a variabilidade depende tanto da equipe quanto do parâmetro considerado.

De modo geral, os intervalos bootstrap mostram que as estimativas pontuais de ϕ e θ estão sujeitas a incerteza decorrente da variabilidade dos jogos observados. Dessa forma, o procedimento permitiu complementar as estimativas médias utilizadas no modelo de simulação, fornecendo uma medida da precisão associada a cada parâmetro.

5 Atividade Extra

O modelo original estima os parâmetros ofensivos e defensivos de cada equipe a partir da média dos gols marcados e sofridos nos jogos já realizados. Dessa forma, todos os jogos possuem a mesma importância na estimação, independentemente de terem ocorrido no início do campeonato ou nas rodadas mais recentes.

Como alteração ao modelo, foi proposta a utilização de um decaimento temporal, com o objetivo de atribuir maior importância à forma atual das equipes. A motivação é que o desempenho de um time pode se modificar ao longo do campeonato devido a fatores como mudanças táticas, troca de treinador, lesões, contratações ou simplesmente melhora ou piora de desempenho. Assim, partidas recentes podem fornecer uma indicação mais representativa da força atual da equipe do que partidas disputadas muitas rodadas anteriormente.

Para incorporar esse efeito, foi utilizado um fator de decaimento igual a 0,90. Para cada partida já realizada, o peso é calculado por $w_j = 0{,}90^{(R-r_j)}$, em que R representa a rodada mais recente disponível e r_j representa a rodada em que o jogo j foi disputado.

Dessa forma, um jogo ocorrido na rodada mais recente possui peso $0{,}90^0 = 1$, enquanto um jogo realizado uma rodada antes possui peso 0,90, um jogo realizado duas rodadas antes possui peso $0{,}90^2 = 0{,}81$, e assim sucessivamente. Portanto, quanto mais antiga for a partida, menor será sua influência sobre a estimação dos parâmetros.

A partir desses pesos, as médias simples utilizadas no modelo original são substituídas por médias ponderadas. Para os jogos em que uma equipe atua como mandante, por exemplo, o parâmetro ofensivo θ_m passa a ser a média ponderada dos gols marcados em casa, enquanto ϕ_m corresponde à média ponderada dos gols sofridos em casa. De maneira análoga, θ_v e ϕ_v são calculados a partir dos jogos disputados como visitante.

Em termos gerais, uma média ponderada pode ser escrita como

$$\bar{x}_w = \frac{\sum_j w_j x_j}{\sum_j w_j},$$

de modo que os resultados recentes contribuem mais para a estimativa do que os resultados antigos.

Essa modificação mantém a estrutura geral do modelo de Poisson e da simulação de Monte Carlo, alterando apenas a forma como os parâmetros das equipes são estimados. Assim, busca-se fazer com que as probabilidades simuladas reflitam melhor o momento recente de cada equipe, em vez de considerar que uma atuação do início do campeonato possui exatamente a mesma relevância que uma atuação da rodada atual.

O valor de 0,90 controla a velocidade desse decaimento: valores mais próximos de 1 produziriam uma redução mais lenta da importância dos jogos antigos, enquanto valores menores dariam ainda mais importância às partidas recentes. Neste trabalho, foi adotado 0,90 como fator de ponderação para comparar os resultados desse modelo com os obtidos pelo modelo original.

A Figura 8 apresenta uma comparação entre as probabilidades estimadas pelos dois modelos considerados neste trabalho: o modelo original e o modelo ponderado. As Tabelas 5 e 6 apresentam, respectivamente, as probabilidades estimadas para cada equipe ser campeã e para terminar a competição entre as quatro últimas posições (Z4).

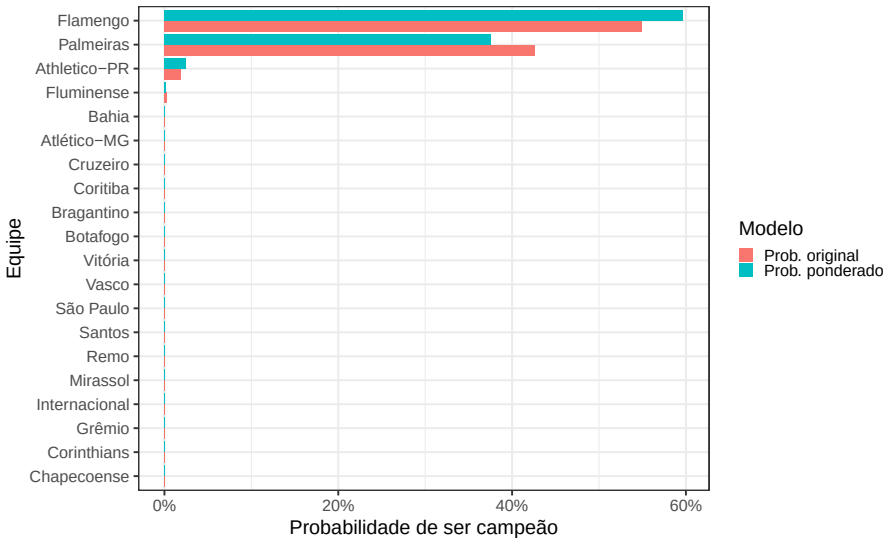


Figura 8: Comparação da probabilidade de ser campeão em cada modelo

Tabela 5: Probabilidade de ser campeão em cada modelo

Time	**Prob. original (%)**	**Prob. ponderada (%)**
Flamengo	55,0%	59,7%
Palmeiras	42,7%	37,5%
Athletico-PR	1,9%	2,5%
Fluminense	0,3%	0,2%
Atlético-MG	0,0%	0,0%
Bahia	0,0%	0,0%
Botafogo	0,0%	0,0%
Bragantino	0,0%	0,0%
Chapecoense	0,0%	0,0%
Corinthians	0,0%	0,0%
Coritiba	0,0%	0,0%
Cruzeiro	0,0%	0,0%
Grêmio	0,0%	0,0%
Internacional	0,0%	0,0%
Mirassol	0,0%	0,0%
Remo	0,0%	0,0%
Santos	0,0%	0,0%
São Paulo	0,0%	0,0%
Vasco	0,0%	0,0%
Vitória	0,0%	0,0%

Na Tabela 5, observa-se que as maiores probabilidades de título estão concentradas em três equipes: Flamengo, Palmeiras e Athletico-PR. No modelo original, o Flamengo apresenta probabilidade de 55% de ser campeão, enquanto o Palmeiras apresenta $42,7\%$. Com a aplicação da ponderação, esses valores passam para $59,7\%$ e $37,5\%$, respectivamente. Dessa forma, observa-se um aumento de $4,7$ pontos percentuais na probabilidade estimada para o Flamengo e uma redução de $5,2$ pontos percentuais para o Palmeiras.

O Athletico-PR também apresenta uma alteração relevante entre os modelos, passando de $1,9\%$ no modelo original para $2,5\%$ no modelo ponderado, um aumento de $0,6$ ponto percentual. Para

apenas uma das demais equipes com probabilidades diferentes de zero foram observadas mudanças, sendo ela Fluminense, com as alterações pequenas em números absolutos, passando de $0,3\%$ para $0,2\%$. Algumas equipes apresentam probabilidades iguais a zero nos dois modelos, indicando que, dentro das simulações realizadas, não foram observados cenários em que essas equipes terminassem a competição na primeira colocação.

Tabela 6: Probabilidade de estar no Z4 de cada modelo

Time	**Prob. original (%)**	**Prob. ponderada (%)**
Chapecoense	99,6%	99,4%
Remo	76,6%	72,4%
Vasco	56,2%	61,2%
Mirassol	57,7%	56,1%
Internacional	48,9%	48,4%
Grêmio	19,5%	18,5%
Vitória	15,1%	24,3%
Santos	15,0%	7,8%
Botafogo	4,7%	5,3%
Corinthians	3,1%	2,1%
São Paulo	2,8%	4,0%
Bragantino	0,3%	0,2%
Coritiba	0,2%	0,2%
Atlético-MG	0,1%	0,0%
Cruzeiro	0,1%	0,0%
Athletico-PR	0,0%	0,0%
Bahia	0,0%	0,0%
Flamengo	0,0%	0,0%
Fluminense	0,0%	0,0%
Palmeiras	0,0%	0,0%

A Tabela 6 apresenta as probabilidades de cada equipe terminar entre as quatro últimas posições. Nesse caso, observa-se uma concentração maior das probabilidades em algumas equipes. A Chapecoense apresenta a maior probabilidade nos dois modelos, com $99,6\%$ no modelo original e $99,4\%$ no modelo ponderado. Deste modo, a equipe continua a apresentar uma probabilidade elevada, com uma redução de apenas $0,2$ pontos percentuais após a ponderação.

O Remo apresenta $76,6\%$ de probabilidade de terminar no Z4 no modelo original, enquanto no ponderado essa probabilidade é de $72,4\%$. O time Mirassol, por sua vez, apresenta redução de $57,7\%$ para $56,1\%$, enquanto o Internacional passa de $48,9\%$ para $48,4\%$. Em sentido contrário, algumas equipes apresentam aumento na probabilidade de terminar no Z4 após a ponderação. O Vasco passa de $56,2\%$ para $61,2\%$ e o Vitória de $15,1\%$ para $24,3\%$.

Também é possível observar que algumas equipes apresentam probabilidades muito baixas ou nulas de terminar no Z4 nos dois modelos. Athletico-PR e Palmeiras, por exemplo, apresentam probabilidade de $0,00\%$ em ambas as abordagens. Para São Paulo e Botafogo, embora as probabilidades sejam baixas, observa-se um aumento no modelo ponderado. O São Paulo, por exemplo, passa de $2,8\%$ para 4%, enquanto o Botafogo passa de $4,7\%$ para $5,3\%$.

De maneira geral, a comparação entre os modelos mostra que a aplicação da ponderação modifica as probabilidades estimadas, embora as principais concentrações permaneçam semelhantes. Na estimativa de título, Flamengo e Palmeiras continuam concentrando a maior parte da probabilidade, enquanto, na estimativa de participação no Z4, Chapecoense e Remo permanecem entre as equipes com maiores probabilidades. As diferenças observadas entre os modelos permitem avaliar como a introdução dos pesos influencia as estimativas produzidas pelo modelo estatístico, sem alterar de forma generalizada a estrutura dos resultados.

Tabela 7: Erros padrão de Monte Carlo das estimativas do modelo com decaimento temporal.

Time	EP_{MC}(campeão)	EP_{MC}(rebaixamento)	EP_{MC}(G4)	EP_{MC}(pontos)
Athletico-PR	0.00156	0	0.00401	0.0463
Atlético-MG	0.000224	0.000200	0.00412	0.0479
Bahia	0.000224	0.000100	0.00415	0.0465
Botafogo	0	0.00224	0.000913	0.0486
Bragantino	0.000141	0.000499	0.00271	0.0469
Chapecoense	0	0	0	0.0464
Corinthians	0	0.00144	0.00114	0.0456
Coritiba	0.000141	0.000447	0.00269	0.0460
Cruzeiro	0.000173	0.000100	0.00387	0.0462
Flamengo	0.00491	0	0.000424	0.0459
Fluminense	0.000387	0.000100	0.00489	0.0459
Grêmio	0	0.00388	0.000173	0.0458
Internacional	0	0.00500	0	0.0453
Mirassol	0	0.00496	0	0.0450
Palmeiras	0.00484	0	0.000851	0.0474
Remo	0	0.00447	0	0.0453
Santos	0	0.00268	0.000698	0.0482
São Paulo	0	0.00197	0.000907	0.0466
Vasco	0	0.00487	0	0.0456
Vitória	0	0.00429	0.000141	0.0443

Os resultados apresentados na tabela indicam que os erros padrão das probabilidades variam conforme a estimativa de cada equipe. Probabilidades próximas de zero ou de um podem apresentar erros padrão muito pequenos, ou mesmo iguais a zero quando o evento não ocorreu em nenhuma das simulações. Isso não significa, entretanto, que o evento seja impossível, mas apenas que não foi observado no conjunto finito de temporadas simuladas. Por outro lado, probabilidades intermediárias tendem a apresentar erros padrão maiores.

No caso da pontuação esperada, os erros padrão são próximos de 0,045 a 0,048 ponto, indicando que a incerteza numérica das médias estimadas é relativamente semelhante entre as equipes. Esses valores devem ser interpretados na escala da pontuação, enquanto os erros padrão das probabilidades estão expressos na escala de proporções.

A comparação entre o modelo original e o modelo com decaimento temporal deve considerar os erros padrão correspondentes a cada modelo, pois as estimativas e suas variabilidades dependem dos resultados das respectivas simulações. Assim, diferenças entre as estimativas pontuais devem ser analisadas levando em conta também a magnitude desses erros. Ressalta-se, contudo, que o erro padrão de Monte Carlo avalia apenas a variabilidade associada ao número finito de simulações; ele não mede a incerteza decorrente das hipóteses do modelo nem garante sua capacidade de prever os resultados reais do campeonato.

5.1 Limitações do estudo e considerações finais

O modelo desenvolvido permite analisar diferentes cenários para a classificação final do Campeonato Brasileiro de 2026 por meio de simulações de Monte Carlo. Entretanto, os resultados devem ser interpretados considerando algumas limitações. Em particular, não foi realizada uma avaliação da capacidade preditiva do modelo com base em partidas não utilizadas na estimação dos parâmetros. Assim, embora as simulações forneçam estimativas das probabilidades de diferentes resultados, não é possível afirmar, a partir das análises realizadas, que o modelo apresenta determinada precisão preditiva ou que suas previsões sejam superiores às de outras abordagens.

Além disso, o modelo utiliza uma representação simplificada do desempenho das equipes, baseada em médias de gols marcados e sofridos e na distribuição de Poisson. Essa construção não incorpora explicitamente todos os fatores que podem influenciar os resultados das partidas, como mudanças de desempenho ao longo da temporada, lesões, suspensões e outras circunstâncias específicas de cada confronto. Portanto, as probabilidades obtidas devem ser entendidas como resultados condicionados às hipóteses adotadas e às informações disponíveis na data de coleta dos dados.

O bootstrap foi utilizado para investigar a variabilidade das estimativas dos quatro parâmetros do modelo. Essa análise permite avaliar a incerteza associada à estimação desses parâmetros, mas não substitui uma avaliação da capacidade preditiva do modelo. Da mesma forma, a quantidade finita de simulações de Monte Carlo introduz erro numérico nas estimativas, de modo que os resultados não devem ser interpretados como valores exatos.

Dessa forma, o trabalho apresenta uma aplicação de simulação de Monte Carlo para estudar possíveis classificações finais do campeonato, acompanhada de uma análise da variabilidade dos parâmetros por bootstrap. As conclusões permanecem restritas ao modelo proposto, aos dados utilizados e às hipóteses estabelecidas, não constituindo uma validação empírica de sua capacidade de previsão.

6 Conclusão

O objetivo deste trabalho foi utilizar métodos de Monte Carlo para predizer, com base na situação parcial do Campeonato Brasileiro de 2026, as probabilidades associadas aos principais desfechos da competição. Para isso, adotou-se um modelo simplificado no qual o número de gols marcados por cada equipe segue uma distribuição de Poisson, cujo parâmetro combina a taxa ofensiva do time com a taxa defensiva do adversário, estimadas diretamente pelas médias de gols marcados e sofridos observadas até 03/09/2026. A partir de $B = 10.000$ simulações dos jogos restantes, foi possível construir uma classificação final empírica do campeonato e responder às seis perguntas propostas no roteiro da atividade.

As estimativas obtidas indicam que a disputa pelo título está fortemente concentrada em Flamengo e Palmeiras, que juntos correspondem à quase totalidade dos campeonatos simulados. O restante da tabela apresenta probabilidades residuais de título já a partir da terceira colocação atual.

De forma simétrica, a zona de rebaixamento mostrou-se dominada por cinco equipes (Chapecoense, Remo, Mirassol, Vasco e Internacional), com as demais apresentando probabilidades próximas de zero. A baixa probabilidade estimada de o campeonato ser decidido por critérios de desempate (6,07%) sugere que, no cenário atual, a distância em pontos entre as equipes tende a ser suficiente para evitar empates na liderança na maior parte das simulações.

Os limiares de pontuação identificados, de aproximadamente 76 pontos para 90% de chance de título e 45 pontos para 95% de chance de permanência na Série A, fornecem um parâmetro objetivo para avaliar, ao longo das rodadas finais, a situação de qualquer equipe frente a esses dois objetivos, sem depender diretamente da posição corrente na tabela.

A análise de variabilidade via bootstrap acrescentou uma camada importante de honestidade estatística ao trabalho, ao evidenciar que as estimativas pontuais de θ e ϕ não possuem a mesma precisão entre as equipes, sendo naturalmente mais incertas para os times com menor número de

jogos disputados em uma dada condição de mando. Essa constatação reforça que as probabilidades reportadas devem ser interpretadas como estimativas obtidas sob um modelo cujos próprios parâmetros de entrada carregam incerteza, incerteza essa que não foi propagada para a simulação principal, já que θ e ϕ foram fixados em seus valores pontuais antes da etapa de Monte Carlo.

Por fim, a atividade extra, na qual se propôs um esquema de ponderação por decaimento temporal (fator 0,90 por rodada) para dar maior peso aos jogos mais recentes, mostrou que essa alteração desloca de forma perceptível, ainda que não drástica, as probabilidades estimadas para equipes com maior variação de desempenho ao longo do campeonato, como Vitória e Vasco. Isso sugere que a hipótese de estabilidade de desempenho implícita no modelo original não é inteiramente inócua, embora sua relaxação não tenha alterado a ordenação geral dos favoritos ao título ou ao rebaixamento.

De modo geral, o exercício demonstrou que um modelo relativamente simples, fundamentado em uma hipótese distribucional parcimoniosa para os gols, é suficiente para gerar previsões informativas e consistentes com a hierarquia observada de desempenho das equipes. Ao mesmo tempo, a combinação com técnicas de reamostragem e simulação permitiu quantificar, ainda que parcialmente, as diferentes fontes de incerteza envolvidas, tanto a aleatoriedade inerente aos resultados das partidas quanto a incerteza na estimação dos parâmetros do modelo.

7 Referências

[1] Gamerman, D. and Lopes, H. (2006). *Markov chain Monte Carlo: stochastic simulation for Bayesian inference*. Chapman and Hall/CRC.

[2] Robert, C. P. and Casella, G. (2004). *Monte Carlo Statistical Methods*. Springer-Verlag.

[3] Givens, G and Hoeting, J. (2005). *Computational Statistics*. Wiley Series.

[4] Thisted, R. A. (1988). *Elements of Statistical Computing: numerical computation*. Chapman and Hall.

[5] Tan, M. T., Tian, Guo-Liang and Ng, K. W. (2009). *Bayesian missing data problems: EM, data augmentation and Noniterative Computation*. Chapman and Hall.